

進度報告大綱 — Crawler C Data Normalization Engine

專題名稱：C 語言大學排名資料正規化引擎 (Clawer-C-Data-Normalization-Engine) 報告日期：2026-05-09 累計進度：Session 6 (第六輪弱點導向測試與修正完成)

組員名單：

學號	姓名
b11402037	高恩在
b11402053	林秉學

一、Introduction | 簡介

1.1 專題背景與動機

- 上游爬蟲系統從 QS、THE、Shanghai Ranking 等多個大學排名來源抓取資料，輸出格式高度異質。
- 主要異質性來源：
 - 大學名稱：大小寫不一、縮寫 (MIT、ETH、KAUST 等)、標點與空白差異。
 - 國家名稱：縮寫 (U.S.A.、UK、PRC)、官方長名 (Federal Republic of Germany)、「The X」前綴變體。
 - 排名格式：純數字、區間 (101-150)、文字前綴 (Top 100、Rank 53、=201、#10、201+)。
 - 分數：含百分號、空白、無效值等多種髒資料。

1.2 研究問題

在不修改下游分析邏輯的前提下，如何將異質性爬蟲輸出 (多種大學名稱格式、排名區間字串、不一致的國家縮寫) 轉換為可直接比較的數值紀錄？

1.3 設計選擇

- 以 C 語言 (C11, gcc, -Wall -Wextra) 實作核心引擎，而非 Python/pandas。
- Rationale：大量 CSV 批次處理時維持低記憶體佔用與可預期的執行時間，避免引入 Python 執行期依賴。

1.4 系統範圍

- 輸入：爬蟲輸出 CSV (11 欄原始格式)。
- 輸出：標準化 CSV (5 欄：University, Country, Rank Min, Rank Max, Overall Score)。
- 邊界：單機、檔案導向；無資料庫、無 Web API、無外部網路服務依賴。

二、Project Status | 專題進度

2.1 系統架構 (已完成)

- **CLI** 主程式 (`src/main.c`)：互動式選單，協調載入、正規化、預覽、匯出。
- **CSV Reader** (`src/csv_reader.c`)：header 驗證、quoted CSV 解析、BOM 清理、不合法列略過。
- **Normalization Pipeline** (`src/normalizer.c`)：協調名稱、國家、排名、分數四個解析模組。
- **CSV Writer** (`src/csv_writer.c`)：標準化輸出與 quoting/escaping。

2.2 核心模組實作狀態

模組	檔案	狀態
Name Normalizer	<code>name_normalizer.c</code>	☑ 已完成 (含縮寫清單)
Country Normalizer	<code>country_normalizer.c</code>	☑ 已完成 (含 38+ 別名)
Rank Parser	<code>rank_parser.c</code>	☑ 已完成 (支援 6 種格式)
Score Parser	<code>score_parser.c</code>	☑ 已完成 (含前導小數點修正)
CSV Reader / Writer	<code>csv_reader.c</code> / <code>csv_writer.c</code>	☑ 已完成
Utils (共用工具)	<code>utils.c</code>	☑ 已完成
Requirement Parser	<code>requirement_parser.c</code>	☐ 尚未實作

2.3 弱點導向測試方法論

- 流程：靜態分析 → 探針程式 → 修正 → 回歸驗證。
- 累計六輪 Session 修正 (A-T 共 17 項修正項目)。

2.4 累計測試結果 (Session 6 後)

測試套件	通過 / 總計
test_normalizer	17 / 17

測試套件	通過 / 總計
test_extreme	139 / 139
test_scale	31 / 31
test_weakness	43 / 43
test_regression2 ~ 6	372 / 372
合計	602 / 602 □

2.5 Session 6 主要成果

- **Bug R** : country_normalizer 補上「The X」前綴、PR China、官方長名共 38 個別名。
- **Bug S** : score_parser 修正前導小數點誤解析 (.5 從 5.0 修正為 0.5)。
- **Bug T** : name_normalizer 加入 KAUST、HKU 大學縮寫。

三、Encountered Problems | 待解決問題

3.1 已知技術限制 (尚未修正)

- **Score Parser** 精度捨入
- %.2f 格式下 99.999 輸出為 100.00 (四捨五入超出滿分)。
- 屬 C 標準庫正常行為，需評估是否改用截斷 (floor)。
- 非 **ASCII** 字元正規化
- 目前 normalizer 為 ASCII-only 邏輯。
- "École"、"Universität"、"São Paulo" 中的 é / ä / ã 等字元直接傳遞，不做 Unicode 正規化 (NFC/NFD)。
- 修正需引入 Unicode 函式庫，超出當前設計範圍。

3.2 功能缺口

- **Requirement Parser** 尚未實作
- src/requirement_parser.c 目前為空檔 (1 行)。
- 影響 GMAT / GRE / GPA / IELTS / TOEFL / Duolingo 等入學要求欄位的解析。

3.3 架構面開放問題 (**README** 開放問題章節)

- MAX_FIELDS = 11 為硬編碼常數；上游爬蟲若新增欄位是否能優雅降級？
- 國家別名表為靜態，缺少可維護的更新流程。
- score parser 的哨兵值 -1 與下游分析的處理規則尚未明確契約化。

3.4 開發流程上的痛點

- 多 session 修正下 patch 同步機制 (`apply_sessionN_patches.py`) 為臨時方案，需要正規化。

四、On-going Work | 後續工作

4.1 短期 (下一 Session, ~ 兩週)

- 實作 `requirement_parser.c` , 支援 GMAT/GRE/GPA/IELTS/TOEFL/Duolingo 六類入學要求欄位解析。
- 補上對應的 unit test 與 regression7 測試套件。
- 修正前述 `MAX_FIELDS` 硬編碼問題，改為動態欄位偵測或以 header 驅動。

4.2 中期 (一個月內)

- 引入 Unicode 函式庫 (如 ICU 或 `utf8proc`) , 處理非 ASCII 字元正規化。
- 設計國家別名表的外部化機制 (改為從外部 mapping 檔載入，而非硬編碼於原始碼) 。
- 與下游分析模組明確化哨兵值 (`-1`) 契約，或改為 `NULL` / 空欄位設計。

4.3 長期 / 整合

- 與上游爬蟲主系統整合，導入 CI 自動化流程：爬蟲執行 → 正規化引擎 → 下游資料庫。
- 撰寫 API 形式的 library 介面 (除 CLI 外提供 `libnormalizer.a` / `.so`) 。
- 效能基準測試 (吞吐量、記憶體佔用) , 對照 Python/pandas 實作驗證 C 設計選擇的優勢。

4.4 文件與報告

- 整合 6 份 Session 測試報告為一份完整的實驗章節。
- 撰寫使用者文件 (含 API reference) 。
- 準備期末展示之 demo 流程與測試資料集。

五、References | 參考文獻

待補：以下為建議引用之來源類別，後續可依實際使用補上正式格式。

5.1 排名資料來源

- QS World University Rankings (官方網站與資料說明) 。
- Times Higher Education (THE) World University Rankings。
- Shanghai Ranking / Academic Ranking of World Universities (ARWU)。

5.2 技術標準

- ISO 3166-1 : 國家代碼標準 (用於國家別名映射依據) 。
- RFC 4180 : CSV 格式標準 (quoting / escaping 規範) 。
- Unicode Standard Annex #15 : Unicode Normalization Forms (NFC/NFD , 後續 ASCII 限制相關) 。

5.3 工具與函式庫

- GNU Make Manual。
- C11 Language Standard (ISO/IEC 9899:2011) 。
- gcc Compiler Documentation。

5.4 內部文件

- 本專案 README.md 。
- `c_engine/docs/architecture.md` — 系統架構圖與資料流。
- `test-report.md` — Session 1-6 累計測試報告。
- Sessions 1-6 修正紀錄與 patch 腳本 (`apply_sessionN_patches.py`) 。

報告大綱產生工具 : *Cowork / Claude*